

Roadmap

10 pasos para llevar un agente a producción

PARTE 1 · Fundamentos y arquitectura del agente

01

Documentos de Negocio

- Selecciona 3 a 5 documentos representativos
- Formatos válidos: .pdf, .docx, .txt
- Organiza en carpeta /docs con README.md
- Define qué preguntas debe responder el agente

02

Embeddings → Vector DB

- Aplica chunking + overlap a los documentos
- Genera embeddings (text-embedding-3-small, voyage-3)
- Carga vectores en Pinecone, Qdrant o Chroma
- Incluye metadata: fuente, fecha, sección

03

Agente Orquestador

- Define rol y system prompt del agente principal
- Lista herramientas y workers disponibles
- Establece criterios de delegación
- Define formato de salida estándar

04

Agentes Workers

- Crea al menos 2 agentes especializados
- Worker de búsqueda semántica
- Worker de consulta SQL
- Implementa manejo de errores y reintentos

05

Agente Fiscalizador

- Valida que la respuesta cite fuentes
- Detecta datos sensibles o PII
- Verifica que responda la pregunta original
- Retorna {ok, issues, corrected}

06

Búsqueda Semántica (KNN)

- Configura retriever con k=5
- Prueba con 10 consultas reales
- Mide precisión@k manualmente
- Evalúa re-ranking o hybrid search

Roadmap

UNIVERSIDAD
ADOLFO IBÁÑEZ

10 pasos para llevar un agente a producción

PARTE 2 · Persistencia, versionado y go-live

07

SQL para Registros

- Diseña tabla interactions para trazabilidad
- Campos: id, timestamp, query, response, tokens, latency
- Conecta vía SQLAlchemy o cliente nativo
- Registra cada interacción del orquestador

08

Subir a GitHub

- Estructura: /src, /tests, requirements.txt
- Incluye .env.example y .gitignore
- Documenta setup en README.md
- Mínimo 3 commits significativos

09

Conectar GCP Cloud Run

- Escribe y prueba Dockerfile localmente
- Habilita APIs y crea service account
- Configura Secret Manager para API keys
- Define límites de costo y concurrencia

10

Deploy & Go Live

- Ejecuta gcloud run deploy
- Prueba endpoint con 5 consultas reales
- Monitorea latencia y logs en Cloud Console
- Reporta costo estimado por 1.000 consultas

ENTREGABLE FINAL · URL pública del agente desplegado + repositorio GitHub + reporte breve (latencia, costo por 1.000 consultas, 2 mejoras pendientes).